

Radyoloęu Takip Etmek

oklu Grnm İpuları ve Deneysel Analizler

Hakkı Keman · Ege niversitesi Bilgisayar Mhendislięi Tezli
Yksek Lisans Programı



Sunum Planı



Literatür Taraması

Derin öğrenme ve çoklu görünüm füzyon yaklaşımlarının evrimi



DeneySEL Çalışmalar

FROC metrikleri, görselleştirme ve sonuçların analizi



Kod Mimarisi

PyTorch tabanlı modüler altyapı: veri, model, eğitim, değerlendirme



Canlı Demo

Gerçek zamanlı model eğitimi, test ve görsel çıktılar


Kısa Hatırlatma: Nerede Duruyoruz?

Temel Problem


Meme, 3D elastik bir doku olduğundan CC ve MLO görüntüleri arasında **katı geometrik hizalama** gerçekçi değildir. Görünümler arası lezyonların eşleştirilmesi zorlu bir yapısal problem oluşturur.

Önerilen Çözüm: CEN

Correspondence Estimation Network (CEN), morfolojik Siamese eşleştirme ile iki görünüm arasındaki semantik benzerlikleri öğrenir; katı koordinat dönüşümlerine ihtiyaç duymaz.



Derin Öğrenme Yaklaşımlarının Evrimi




Literatür, **tek görünüm dedektörlerinden** çoklu görünüm bilgi füzyonuna, oradan da **radyolog davranışını modellemeye** doğru belirgin bir evrim sergilemektedir.

BG-RCNN

Bipartite Graph Convolutional Network

BG-RCNN, CC ve MLO görünümlerinden elde edilen bölge önerileri (RoI) arasında **çapraz görünüm yazışmalarını** öğrenmek için iki taraflı bir graf evrişim ağı kullanır.

- RoI çiftleri arasında mesaj geçişi ile bağlam zenginleştirme
- Graf yapısı sayesinde global görünüm ilişkileri modellenir
- Faster R-CNN omurgası üzerine inşa edilmiştir



BG-RCNN: Ne Getirdi, Ne Eksik Kaldı?

Katkılar

- **Pseudo-landmark** kullanımı ile geometrik ön bilgi modele dahil edildi
- Görünümler arası bağlamsal özellikler graf evrişimi ile zenginleştirildi
- Çapraz görünüm füzyonunda öncü bir çerçeve sunuldu

Sınırlar

- Pseudo-landmark tahmini **ek hata kaynağı** oluşturmaktadır
- Elastik meme dokusu, katı geometrik varsayımlarla tam uyum sağlayamaz
- Hizalama hataları yüksek False Positive oranına yol açabilir

AG-RCNN: "Act Like a Radiologist"

Yaklaşım

AG-RCNN, radyologların iki görünümü **eş zamanlı ve dikkatli** biçimde inceleme davranışını modellemek için **attention mekanizmaları** ve bilgi füzyon modülleri kullanır.

Sınırlar

Geometrik kısıtlamalar (epipolar geometri vb.) **rijit varsayımlar** içerir. Yüksek deformasyonlu vakalarda füzyon kalitesi düşebilir; annotation maliyeti yüksektir.




MommiNet-v2

Nipple-Distance Tabanlı Geometrik Hizalama

MommiNet-v2, meme ucuna (nipple) olan **öklid mesafesini** geometrik bir referans noktası olarak kullanarak CC ve MLO görünümelerini hizalar.

- 3D meme anatomisinden türetilmiş geometrik ön bilgi
- Ancak **3D → 2D projeksiyon** sırasında derinlik bilgisi kaybolur
- Nipple tespitindeki hatalar tüm hizalamayı olumsuz etkiler



FocalNet-DINO: Transformer Tabanlı Dedektör

Neden Baseline Olarak Seçildi?

FocalNet-DINO, **DINO** (Detection with Transformers) mimarisini **FocalNet** omurgasıyla birleştirerek nesne tespitinde son teknoloji performansı sunar. Esnek dikkat penceresi sayesinde hem lokal hem global bağlamı yakalar.

- Query tabanlı dedeksiyon: anchor-free, NMS gerektirmez
- Yüksek çözünürlüklü özellik piramidi (FPN)
- Büyük ölçekli ön-eğitimden transfer öğrenimi

Üstünlüğü

Tek görünüm
tespitinde güçlü
FROC performansı


Sınırı

Çoklu görünüm
bilgisini yerel olarak
kullanamaz

Rolü

CEN modülünün entegre edildiği temel ağ

Bizim Yaklaşımımız: Neden CEN?



Katı Geometriden Esnek Morfolojiye

Mevcut yöntemler geometrik referans noktalarına (landmark, nipple, epipolar çizgi) dayanır. Bu varsayımlar elastik meme dokusunda çoğunlukla **kırılığandır.**

CEN (Correspondence Estimation Network), Siamese ağ yapısıyla iki görünümünden elde edilen gömme vektörleri arasındaki **semantik ve morfolojik benzerliği** öğrenir; koordinat dönüşümü gerektirmez.

PyTorch Altyapısına Giriş



data.py

Veri yükleme, eşleştirme ve ön işleme



models.py

Ağ mimarisi ve özellik çıkarımı




train.py

Eğitim döngüsü, kayıp ve optimizasyon



calc_metrics2.py

FROC hesaplama ve performans değerlendirme



Veri İşleme Katmanı

PAIRDataset

CC ve MLO görünümelerini **eşleştirilmiş çift** olarak yükler. Her hasta için ilgili görünüm çifti belirlenerek tensor formatına dönüştürülür.

- Görünüm eşleştirme: hasta ID ve lateralite bazında
- Augmentation: yatay çevirme, normalize edilmiş yoğunluk


ClfDataset

Sınıflandırma görevi için etiketi (malign/benign) taşıyan veri seti sınıfıdır. **PAIRDataset** üzerine inşa edilerek eğitim ve test bölümlerine ayrılır.

- Label encoding ve class imbalance stratejisi
- DataLoader ile mini-batch akışı sağlanır

 Her iki sınıf da `torchvision.transforms` ile standart ön işleme (resize → normalize → tensor) adımlarını uygular.

MAX_model: Ağ Mimarisi




Dondurulmuş ResNet50 Omurgası

ImageNet ile ön-eğitilmiş ResNet50'nin ilk katmanları dondurulur (`requires_grad=False`). Bu sayede düşük seviyeli özellikler korunurken üst katmanlar domain'e özgü eğitim alır.

- Layer1–3: Frozen (genel görsel özellikler)
- Layer4 + FC: Fine-tuned (mamografi'ye özgü)
- Çıktı: 512 boyutlu gömme vektörü

Siamese Network ve Kosinüs Benzerliği



İki görünüm **ağırlık paylaşımı** (weight-sharing) aynı encoder'dan geçirilir. Elde edilen gömme vektörleri arasındaki **kosinüs benzerliği**, görünümün semantik uyumunu ölçer ve CEN modülüne girdi sağlar.

Eğitim Döngüsü

Kayıp ve Optimizasyon

Binary Cross Entropy (BCE) kaybı, malign/benign ikili sınıflandırma için kullanılır. **Adam** optimizatörü ile adaptif öğrenme hızı sağlanır ($lr=1e-4$, $weight_decay=1e-5$).

Aşırı Öğrenmeyi Önleme

- **Early stopping:** Doğrulama kaybı iyileşmediğinde eğitim durdurulur
- **Dropout:** FC katmanlarında $p=0.5$
- **LR Scheduler:** ReduceLROnPlateau ile adaptif azaltım

📄 Eğitim süreci her epoch sonunda model ağırlıkları `.pth` formatında kaydedilir; en iyi doğrulama skoru izlenir.


FROC Eğrisi: Neden Bu Metrik?

FROC Nedir?

Free-Response ROC (FROC), her görüntü başına düşen ortalama False Positive (FP/image) sayısına karşın **hassasiyeti (sensitivity)** ölçer. Mamografi değerlendirmesinde standart metriktir.

- Eşik değerine bağımsız değerlendirme imkânı
- FP/image: 0.025, 0.05, 0.1, 0.2, 0.3... noktalarında hesaplanır
- pAUC ile özet skor üretilir

FROC Eğrisi Bileşenleri



CANLI DEMO

Sınıf Ortamında Canlı Demo

1 Modelin Eğitilmesi


`train.py` çalıştırılır; kayıp eğrileri gerçek zamanlı izlenir

2 Test Aşaması


Ayrılmış test seti üzerinde tahminler üretilir, eşik değerleri değiştirilir

3 Görsel Çıktılar

`save_cases` fonksiyonu ile ground truth ve prediction bounding box'ları yan yana görselleştirilir



Görselleştirme: Bounding Box Analizi



save_cases Fonksiyonu

Her test vakası için **ground truth** (yeşil) ve **model tahmini** (kırmızı) sınırlayıcı kutular aynı görüntü üzerine işlenir. Bu görselleştirme;

- False Positive konumlarını lezyonla ilişkilendirmeye
- Model hata örüntülerini yorumlamaya
- CEN katkısını kalitatif olarak değerlendirmeye

olarak tanır.

CEN Modülünün Etkisi



Temel Bulgu

CEN modülü, FocalNet-DINO baseline'ına entegre edildiğinde **düşük False Positive rejimlerde ($FP/image < 0.2$) anlamlı iyileşme** sağlamaktadır.

- Çoklu görünüm tutarsızlıklarından kaynaklanan FP'ler azalır
- Yalnızca tek görünümde gözükten sahte bulgular baskılanır
- Sensitivity korunurken spesifisite artar

✓ Bu sonuç, morfolojik Siamese eşleştirmenin geometrik hizalamaya üstünlüğünü deneysel olarak doğrulamaktadır.

Teşekkürler

Soru-Cevap

Sorularınız, yorumlarınız ve katkılarınız için hazırım.

Hakkı Keman

Ege Üniversitesi
Bilgisayar Mühendisliği
Tezli Yüksek Lisans Programı

Sunum Kapsamı

- BG-RCNN · AG-RCNN · MommiNet-v2 · FocalNet-DINO
- CEN Modülü ve PyTorch Kod Mimarisi
- FROC Değerlendirme ve Canlı Demo

